

衍生品展业【知识沉淀】与 AI 赋能方案

团队经验丰富却分散各处，大模型能力已日趋成熟 — 是时候把二者桥接起来

知识沉淀 AI 赋能 展业提效

现状与痛点

PAIN 01

知识散落各处

实战经验分散在 群聊 / 邮件 / 文档 / 口头沟通 多个渠道，碎片化严重，同一个问题反复被不同客户问到，每次都要从头组织回答。

PAIN 02

分支客户激增 专业知识未对齐

新客户接入增多、技术水平参差，FIX 协议对接、北上北港连接人、算法单配置等问题被反复解答，团队在重复劳动上消耗大量精力。

PAIN 03

衍生品 & 极速业务 专业门槛高

FIX Protocol、算法律、券池、估值、风控术语密集；跨系统对接涉及接入方式、重注机制、延迟优化、日志排查 — 缺结构化知识体系，新人和客户都难快速理解全貌。

核心思路

CORE IDEA

把散落的业务经验沉淀为结构化知识，
用 AI 放大展业效率。

下一页：产品定位与工作原理

OTCclaw 衍语

有事【衍语】一下

基于大语言模型的 OTC 衍生品智能助手 — 解决展业各类问题

业务知识问答 客户管理 交易查询 信息提醒 内容生成

工作原理

用户自然语言输入

企微 / 飞书 / CLI 一键入口

构建 System Prompt

角色指令 + 权限

Memory 自动注入 (全局 50 + Agent 30 条)

Skills 目录 (名称 + 简介, 按需获取全文)

LLM 推理 + 工具决策

MiniMax / DeepSeek 等模型

基于 JSON Schema 自主选择调用 Tools

工具执行循环

调用 Tools 获取数据 / 执行操作

Knowledge 按图检索 (关键词匹配 + 评分)

run_skill 执行提示词模板

综合生成回复

LLM 结合工具结果，输出结构化自然语言回答

Memory 常驻上下文，自动注入

Skills 可复用提示词模板

Knowledge 按需检索 FAQ

Tools LLM 自主选择调用

工具全景 (OTCclaw Agent Admin)

客户管理

query_clients view_client

get_client_history add_client

update_client advance_client

rollback_client

知识库

search_knowledge add_knowledge

update_knowledge delete_knowledge

list_knowledge_recent

assign_knowledge_agent

unassign_knowledge_agent

get_knowledge_agents

记忆系统

save_memory search_memory

update_memory

delete_memory

内容生成

generate_image markdown_to_image

write_artifact send_file send_image

交易查询

query_trades trade_summary plot_trades

list_customers query_hedge_short

技能管理

list_skills get_skill save_skill

delete_skill run_skill

提醒与待办

set_reminder list_reminders

cancel_reminder create_todo list_todos

update_todo delete_todo

企微 & 系统

get_status regenerate_videoary

http_request

用户问答：工具调用与知识检索流程

从一次自然语言提问到带引用的结构化回答 — AgentLo 全景



Agent 灵魂 + 个人记忆

每次对话前都会现场“装配”的完整 Prompt

config/agents/otcclaw.md

静态“灵魂”定义“它是谁、会什么、怎么说话”；动态《占位符》注入“此刻它记得什么、手上有什么”

灵魂 (静态 Prompt)

身份 & 能力定位

衍语 / OTC Claw — OTC 衍生品展业助手

客户信息查询与状态流转 (Initial Contact => PRQD, 支持 advance / rollback)

交易成文数据查询 (按管理人自动展开全部交易对手)

客户数据分析、展业建议、战术参考

知识库检索回答 FAQ

工具自举: 按需 save_skill 绑定可复用提示词

回答风格

简洁专业中文, 避免冗长

适度使用 emoji 段落标识 (📌📊📈📉🔍⚠️), 不过度堆砌

严禁记忆回答数据, 必须主动调用工具取最新

建议需结合客户实际状态和需求

工具使用规范 (节选)

query_clients 必须从问题里提取 keyword, 禁止空手全量查询

文件入局走 import_document, add_knowledge 仅限单条 FAQ

报价 Excel 自动路由: 客户报价参数 → import_pricing_schedule; 产品利率矩阵 → import_pricing_quote

管理人名 vs Counterparty: query_clients 只识别管理人名, 需先 list_customers 取映射

“报价”语义消歧: 具体客户 → view_client; 货币/期限 → query_pricing_quote

需要外部公开信息 (行情 / 新闻) → 浏览器工具链 mcp_devtools_*

个人记忆 (动态注入占位符)

{{permissions}} 权限清单

根据当前用户的 RBAC 角色展开可用工具与数据范围 (如销售仅看自己的客户; 管理员可见全量)

{{attachments}} 本轮附件

首次消息携带的图片 / Excel / PDF 列表及元信息, 供 LLM 判断是否需要 import_* / parse_excel

{{skills}} Skills 目录

当前 Agent 可用的提示词模板清单 (名称 + 简介), 命中后通过 run_skill 拉取全文

{{memory}} Agent 记忆维度

跨用户共享的 Agent 长期记忆 (SQLite memory 表): 全局 50 条 + 本 Agent 30 条, 覆盖业务常识、术通对齐、历史决策, 所有用户访问同一个 Agent, 都看到相同的 memory。

{{user_context}} 用户 × Agent 记忆 (Workspace)

千人千面的个人偏好与对话摘要 (链文本 + dir: data/workspaces/{agent}/{userId}.md), 每次会话结束 LLM 自动摘要追加, 下次对话时再注入, 记法是“这个用户在使用这个 Agent 时的习惯”。

{{datetime}} 当前时间

服务驻本地时区, 让 LLM 理解“明天 / 上周 / 本月”等相对时间表述

{{memory}} Agent 维度: 跨用户共享, SQLite memory 表 {{user_context}} 用户 × Agent 维度: Workspace md, 会话结束自动摘要

多实例部署 同一灵魂 · 千人千面

所有 OTCclaw 实例【共享同一套】灵魂与基础设施

唯一的差异: {{user_context}} 注入的「用户 × Agent 工作区」不同



调优说明 持续观测 · 闭环改进

每一次问答都【可度量 / 可归因 / 可改进】

全链路埋点 · 工具调用画像 · 异常场景告警, 输出改进反馈闭环

耗时拆解 工具画像 异常告警 改进闭环

每轮问答 · 全链路埋点

单轮耗时拆解 (示例) 总计 3.8s

0.2s 0.9s 1.4s 1.1s 0.2s

上下文装配 LLM 首轮 工具调用 LLM 二轮 调取描述

P50 / P95 总耗时 3.2s / 8.6s 平均工具调用数 2.4 次/轮 超过 P95 触发慢调用日志 告并行调用: >5 次标记为复杂会话

知识检索命中率 78% Agentic Loop 轮次 1.6 轮 平均: 超过 4 轮触发深度分析

采集字段

会话 session_id, user_id, agent_id, channel

耗时分段 ctx / llm_n / tool_n / render_ms

工具名称、参数摘要、返回大小、成功/失败、耗时

LLM 模型、输入/输出 token、tool_use 次数、终止原因

回答是否含引用、用户反馈 (点赞/纠正)

重点关注的异常场景

CRITICAL 多轮工具调用仍未找到答案

Agentic Loop ≥ 3 轮且最终回答“未找到 / 暂无数据 / 无法确认”等模糊表述, 完整保留工具调用链 + 参数 + 返回, 进入人工复核队列。

CRITICAL Agentic Loop 打满上限

达到 max_iterations 仍未收敛, 可能因工具返回噪声过多, Prompt 规则冲突或模型误解意图。

WARN 知识检索命中 0 条

search_knowledge 返回空 Top-K, 多次出现的 query 代表知识盲区, 需补充 FAQ 或导入新文档。

WARN 链工具连续失败

同一工具在一轮内连续 ≥ 2 次失败, 排查参数提取、RBAC 边界、外部依赖。

WARN P95 长尾耗时

耗时突破 P95 阈值, 分段对比定位是 LLM 慢 (切轻量模型) 还是工具慢 (加缓存/索引)。

改进闭环

日志归档 → 人工复盘 → 补 Knowledge / 沉淀 Skill / 调整 Prompt → 回归验证

权限管控 RBAC 三层模型

同一套工具, 【不同角色】看见不同的能力边界

System Admin → Agent Admin → Agent User, 三层工具过滤 + Channel 隔离, 实现细粒度权限控制

System Admin Agent Admin Agent User 三层过滤

